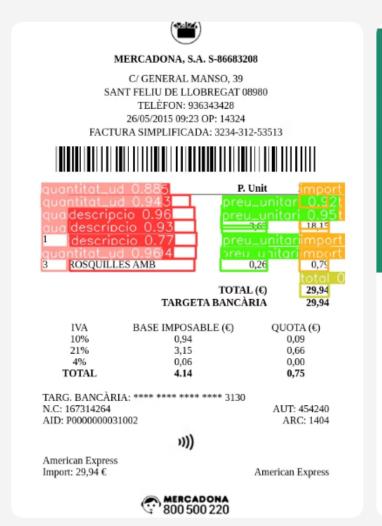
# Ticket Scan

L'aplicació es basa bàsicament en extreure la informació de tiquets de supermercat.

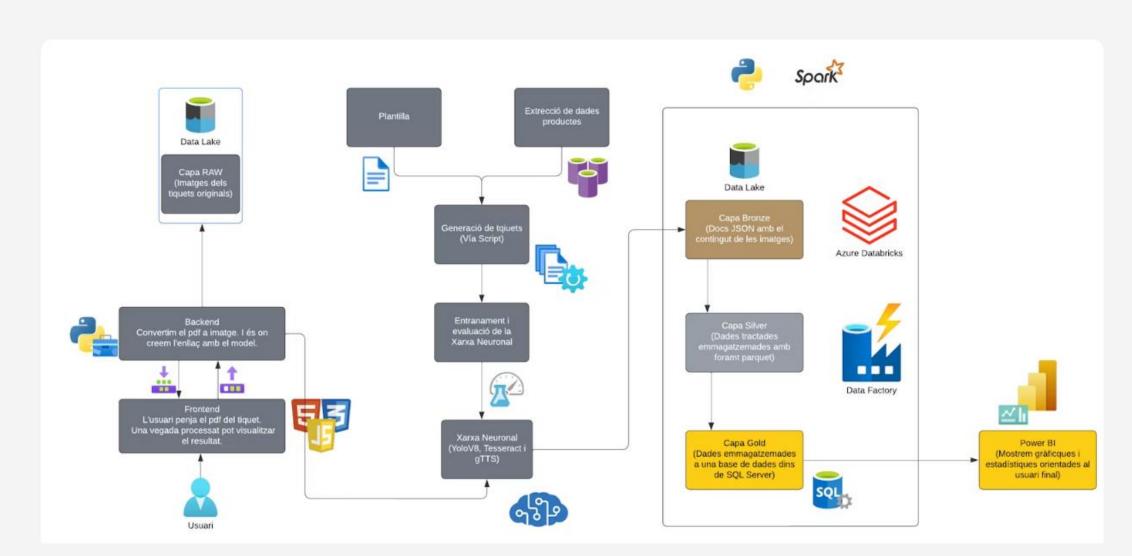
Oriol Torrent i Jaume Juan





### Què és Ticket Scan?

i, com ha estat desenvolupat?

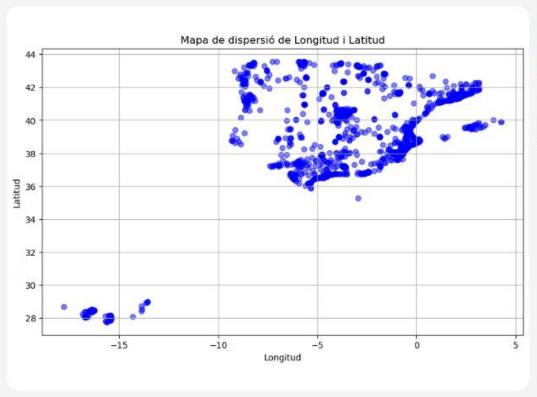


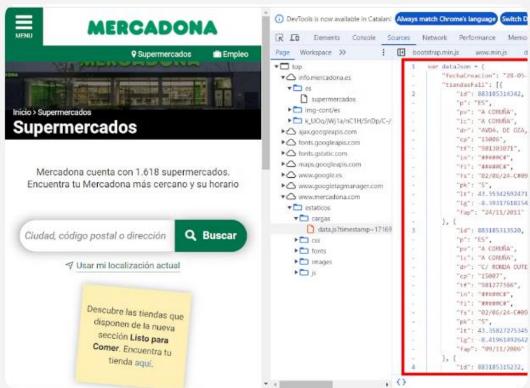
# Preparació i extracció de les dades



#### Dades d'establiments

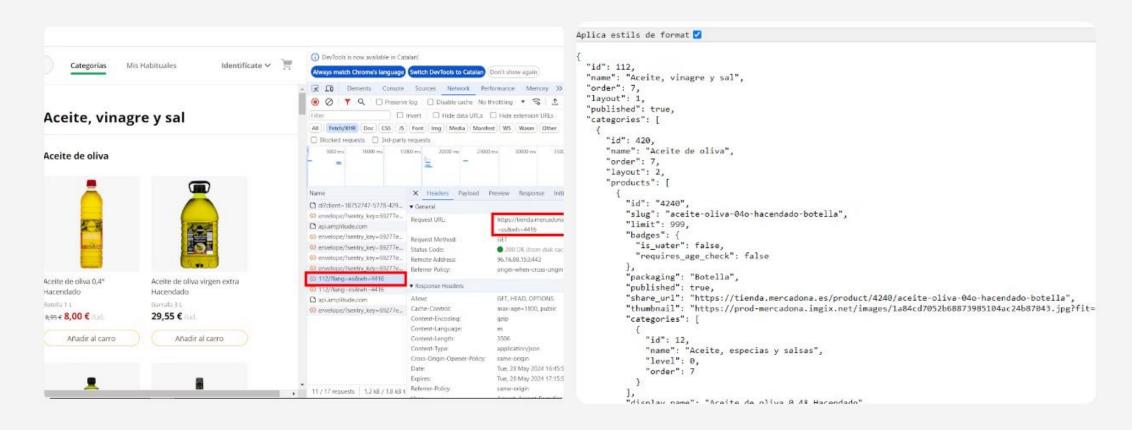
Mitjançant les apis i recursos públics de Mercadona Online, hem extret la informació necessària per generar els tiquets.





#### Dades de Productes

Creem una ETL senzilla per tractar aquestes dades.



#### Plantilla

Creació de la plantilla amb HTML i CSS

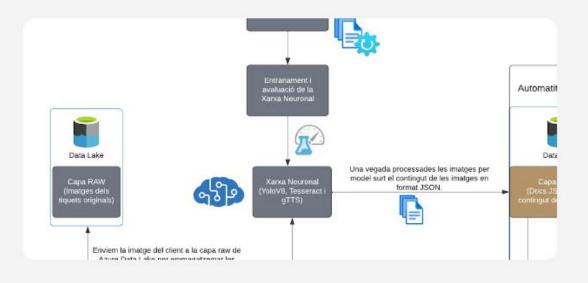


## Creació del Dataset

Amb aquestes dues parts, crearem els tiquets per entrenar el model.

In [52]: t	iquets						
Out[52]:	ticket_id	etiqueta	value	b_1	b_2	b_3	b_4
(	000001.png.png	quantitat_ud	3	(25, 310)	(65, 310)	(25, 330)	(65, 330)
1	1 000001.png.png	descripcio	BAJETA PAL SUAU	(65, 310)	(265, 310)	(65, 330)	(265, 330)
	000001.png.png	preu_unitari	0,85	(307.5, 310)	(377.5, 310)	(307.5, 330)	(377.5, 330)
1	000001.png.png	import	2,54	(430, 310)	(475, 310)	(430, 330)	(475, 330)
	4 000001.png.png	quantitat_ud	1	(25, 330)	(65, 330)	(25, 350)	(65, 350)
1	5 000001.png.png	descripcio	SECRET DE PORC	(65, 330)	(265, 330)	(65, 350)	(265, 350)
	6 000001.png.png	import	2,60	(430, 330)	(475, 330)	(430, 350)	(475, 350)
	7 000001.png.png	quantitat_ud	2	(25, 350)	(65, 350)	(25, 370)	(65, 370)
	000001.png.png	descripcio	AIGUA MINERAL	(65, 350)	(265, 350)	(65, 370)	(265, 370)
	9 000001.png.png	preu_unitari	0,22	(307.5, 350)	(377.5, 350)	(307.5, 370)	(377.5, 370)
10	000001.png.png	import	0,44	(430, 350)	(475, 350)	(430, 370)	(475, 370)
1	1 000001.png.png	quantitat_ud	3	(25, 370)	(65, 370)	(25, 390)	(65, 390)
1:	000001.png.png	descripcio	SORRA PER GAT	(65, 370)	(265, 370)	(65, 390)	(265, 390)

# Train i Test NN



#### **Entrenament Yolo**

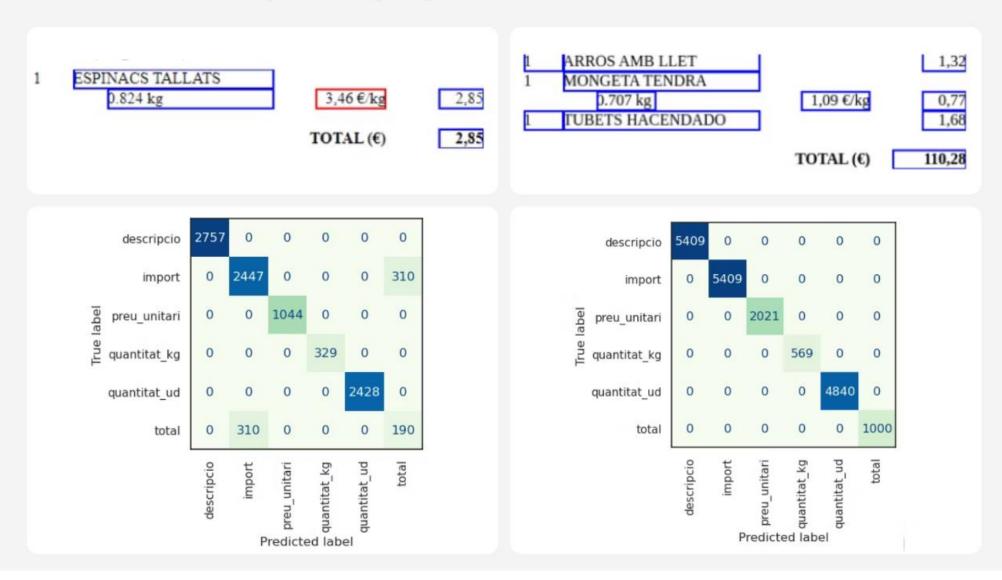
Yolo està entrenat per extreure elements generals de les imatges. Nosaltres li hem fet un **fine-tuning** perquè sàpiga com extreure la descripció, import, preu unitari, etc dels tiquets.



Epoch	GPU_mem	box_loss	cls_loss	dfl_loss	Instances	Size		
9/10	1.44G	0.217	0.1606	0.7707	447	640:	100%	
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95):	100%
	all	30000	1344308	1	0.0942	0.476	0.47	
Epoch	GPU_mem		cls_loss		Instances	Size		
10/10	1.45G	0.1951	0.1464	0.7679	355		100%	
	Class		Instances	Box(P				100
	all	30000	1344308	1	0.0942	0.492	0.487	
0 epochs com	nleted in a	6 938 hours						
ptimizer str				phts/last n	t. 6.2MB			
ptimizer str								
341			I, crozin, wex					
/alidating ru	ns/detect/t	train/weigh	ts/best.pt.					
ltralytics Y					A-A (NVTDTA	T1000 000	O102Mip)	
		168 layers,			gradients,	8.1 GFLOPs		100
	(fused): 1	168 layers,	3006818 pa	rameters, 0	gradients, R	8.1 GFLOPs mAP50		100
odel summary	(fused): : Class all	168 layers, Images 30000	3006818 par Instances	rameters, 0 Box(P 1	gradients, R 0.0942	8.1 GFLOPs mAP50 0.492	mAP50-95): 0.487	100
odel summary d	(fused): 1	168 layers, Images 30000 30000	3006818 pa Instances 1344308	rameters, 0 Box(P 1 1	gradients, R 0.0942 0.0684	8.1 GFLOPs mAP50 0.492 0.457	mAP50-95): 0.487 0.456	100
odel summary d qua	(fused): : Class all escripcio ntitat_ud	168 layers, Images 30000 30000 30000	3006818 par Instances 1344308 389323	rameters, 0 Box(P 1 1 1	gradients, R 0.0942 0.0684 0.0685	8.1 GFLOPs mAP50 0.492 0.457 0.518	mAP50-95): 0.487 0.456 0.507	100
odel summary d qua	(fused): : Class all escripcio ntitat_ud ntitat_kg	168 layers, Images 30000 30000 30000 30000	3006818 pa Instances 1344308 389323 347286	rameters, 0 Box(P 1 1 1	gradients, R 0.0942 0.0684 0.0685	8.1 GFLOPS mAP50 0.492 0.457 0.518 0.399	mAP50-95): 0.487 0.456 0.507 0.393	100
odel summary d qua	(fused): : Class all escripcio ntitat_ud ntitat_kg	168 layers, Images 30000 30000 30000 30000	3006818 pai Instances 1344308 389323 347286 42037 389323	rameters, 0 Box(P 1 1 1	gradients, R 0.0942 0.0684 0.0685 0.067	8.1 GFLOPS mAP50 0.492 0.457 0.518 0.399 0.516	mAP50-95): 0.487 0.456 0.507 0.393 0.508	100
odel summary d qua qua	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import	168 layers, Images 30000 30000 30000 30000 30000	3006818 pai Instances 1344308 389323 347286 42037 389323	rameters, 0 Box(P 1 1 1 1 1	gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225	8.1 GFLOPS mAP50 0.492 0.457 0.518 0.399 0.516 0.611	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61	100
odel summary d qua qua	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari	168 layers, Images 30000 30000 30000 30000 30000 30000	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
lodel summary d qua qua pre speed: 0.1ms	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess,	168 layers, Images 30000 30000 30000 30000 30000 30000 30000 10.7ms in	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 ference, 0.	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
odel summary d qua qua pre	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de	168 layers,	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 ference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
odel summary  d qua qua pre speed: 0.1ms Results saved	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de	168 layers, Images 30000 30000 30000 30000 30000 30000 30000 30000 , 10.7ms in	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 ference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
d qua qua pre speed: 0.1ms tesults saved	(fused): 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de	168 layers, Images 30000 30000 30000 30000 30000 30000 30000 30000 , 10.7ms in	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 ference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
d qua qua qua pre speed: 0.1ms tesults saved	(fused); 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de cabat corre	168 layers, Images 30000 30000 30000 30000 30000 30000 30000 30000 , 10.7ms in	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 iference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
d qua qua qua pre ipeed: 0.1ms tesults saved	(fused); 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de cabat corre	Inages 30000 30000 30000 30000 30000 30000 30000 30000 30000 30000 ctrain	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 iference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100
d qua qua qua pre speed: 0.1ms tesults saved	(fused); 1 Class all escripcio ntitat_ud ntitat_kg import total u_unitari preprocess, to runs/de cabat corre	Images 30000 30000 30000 30000 30000 30000 30000 30000 30000 30000 ctc./train	3006818 pai Instances 1344308 389323 347286 42037 389323 30000 146339 iference, 0.0	rameters, 0 Box(P 1 1 1 1 1 1 1 1	9 gradients, R 0.0942 0.0684 0.0685 0.067 0.0684 0.225 0.0681	8.1 GFLOPS MAP50 0.492 0.457 0.518 0.399 0.516 0.611 0.451	mAP50-95): 0.487 0.456 0.507 0.393 0.508 0.61 0.447	100

#### **Test Yolo**

Després d'algunes iteracions sobre les dades d'entrenament, vam arribar al 100%. Això es degut a la híper especialització que es genera al tenir les dades tan estructurades.



#### **Altres Models Utilitzats**

Tesseract per convertir de imatge a text i gTTS per convertir de text a veu.

```
def text_to_speech(text, lang = 'ca'):
    # return fake_audio

output = gTTS(text=text, lang=lang, slow=False)

output.save("output.mp3")

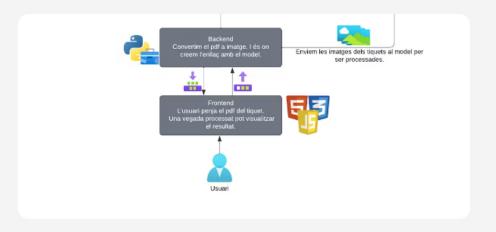
# Llegim el fitxer i el convertim a base64, després el borrem del servidor.
    with open("output.mp3", "rb") as audio_file:
        base64_audio = base64.b64encode(audio_file.read()).decode('utf-8')

os.remove("output.mp3")

return base64_audio
```

```
def get_text(row, pilImg):
    cropped_img = pilImg.crop((row.b_1[0], row.b_1[1], row.b_4[0], row.b_4[1]))
    img = np.array(cropped_img)
    text = pytesseract.image_to_string(img, config="--psm 7")
    return text
```

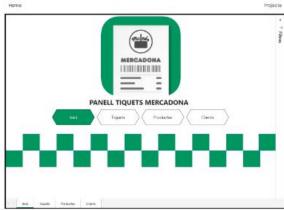
## **Frontend**



## L'usuari Penja el Tiquet

Hem creat la interficie gràfica amb HTML, CSS i JavaScript.



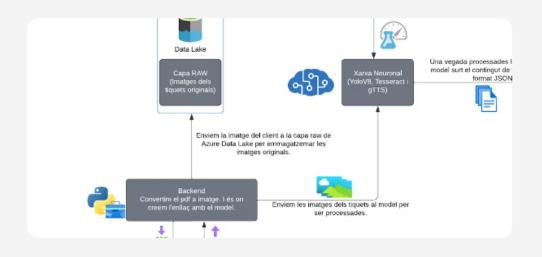


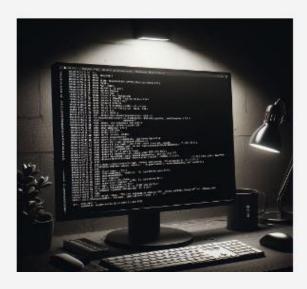
#### Comunicació amb el Backend

Bàsicament, envia l'identificador del usuari i el pdf que hem pujat al servidor per poder ser processat. El servidor li retorna la imatge en base64, la informació i l'àudio en base 64 també.

```
reader.onload = () => {
    const base64 = reader.result.split(',');
   const base64pdf = base64[1];
   const base64extension = base64[0].split('/')[1].split(';')[0];
    const endpoint = `${apiUrl}/pdf/${userId.value}`;
    fetch(endpoint, {
        method: 'POST',
        headers: {
            'Content-Type': 'application/json'
        body: JSON.stringify({
           pdfData: base64pdf,
           extension: base64extension
    .then(response => {
        if (!response.ok) {
            throw new Error("Error al enviar el pdf al servidor");
        return response.json();
    .then(data => {
```

# **Backend**

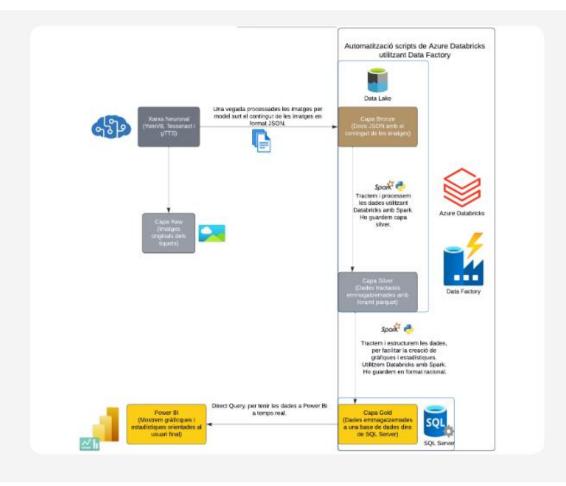




- Hi ha un endpoint pel qual el Frontend ens envia les dades.
- S'implementen les transformacions per aplicar la lògica amb el model.
- Es realitzen dos funcions principals:
  - Retornar la imatge i resultat al Frontend.
  - Inicialitzar la ETL (raw i bronze).

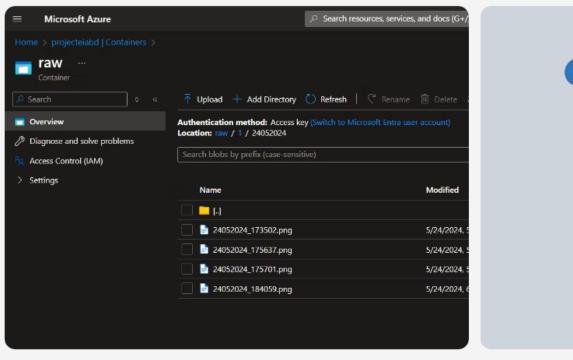
```
# 3. Fem la ETL
# Penjem la foto a la capa Raw, li passem en format de bytes.
save img raw(image content, user id)
# Penjem el contigut en format json a la capa bronze.
save json bronze(ticket info, user id)
# return imatge en base64 per renderitzar-la al front i la informació del tiquet que ha extret la nn.
response = {
    "image": image base64 str,
    "ticket": ticket info,
    "audio": products audio
return jsonify(response), 200, {'Access-Control-Allow-Origin': '*'}
```

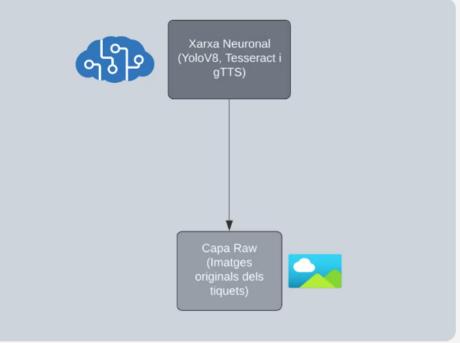
# ETL



## Capa Raw

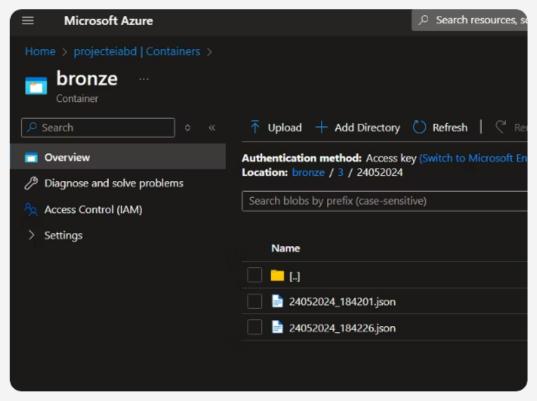
Emmagatzamem les imatges originals que ens envía el client

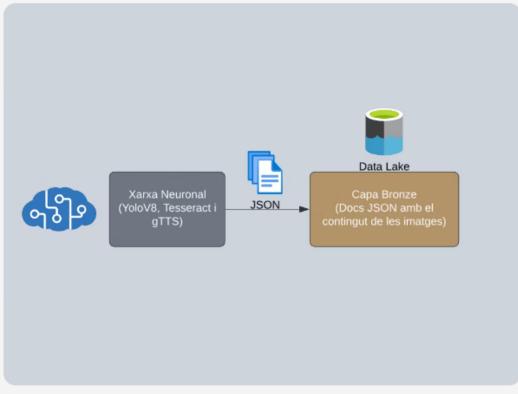




## Capa Bronze

Emmagatzemem els JSON amb la informació extreta dels tiquets





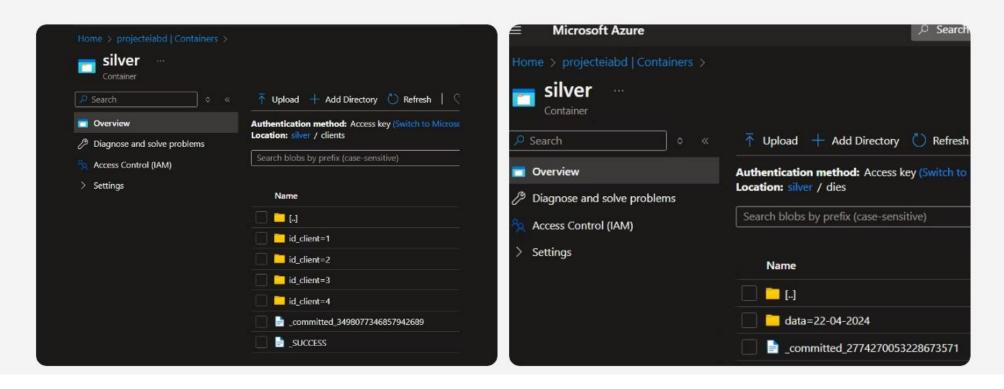
## **Databricks amb Spark**

Utilitzem Databricks amb Spark per tractar les dades de la capa Bronze i passar-les a la capa Silver.



## Capa Silver

Emmagatzemem les dades tractades amb Parquet i particionades per data i id client.



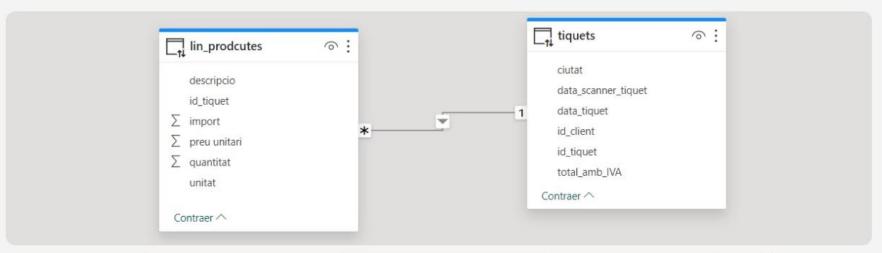
## **Databricks amb Spark**

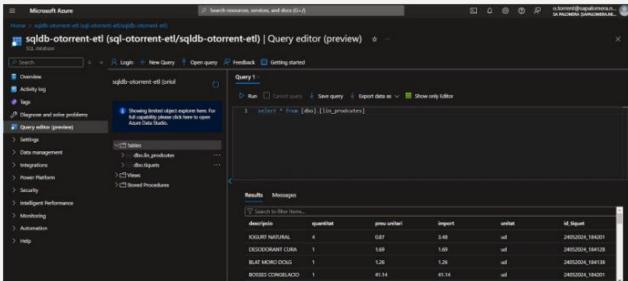
Utilitzem Databricks amb Spark per processar les dades i passar-les a la capa Gold.



#### Capa Gold

Emmagatzamem les dades processades, de forma estructurada i eficient. Per facilitant-ne l'anàlisi i l'extracció de conclusions

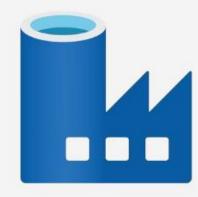




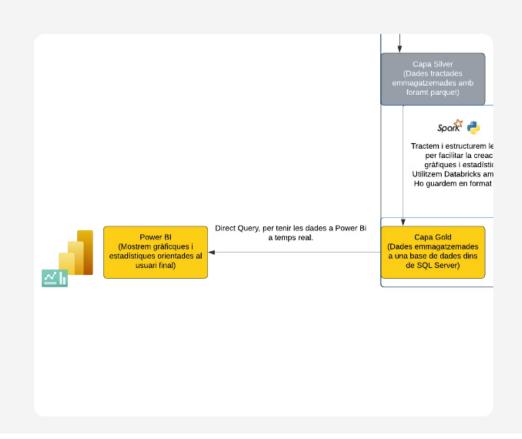
#### Automatització

Hem utiltizat Azure Data Factory amb Azure Databricks per automatizar el procés des que arribant les dades a la capa Bronze fins que arriben a la capa Gold





# **Power Bi**



## **Direct Query**

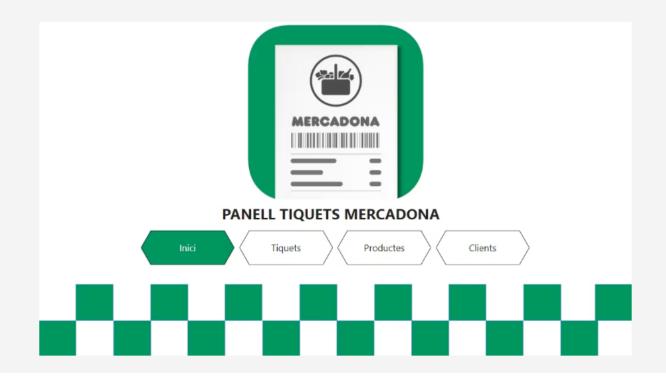
Ens permet agafar les dades directament de la base de dades, permetent tenir-les actualitzades sempre.



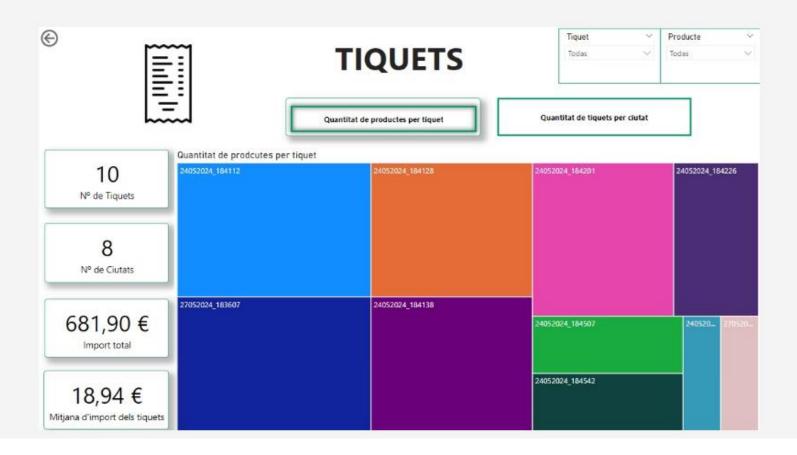
## **Pantalles**

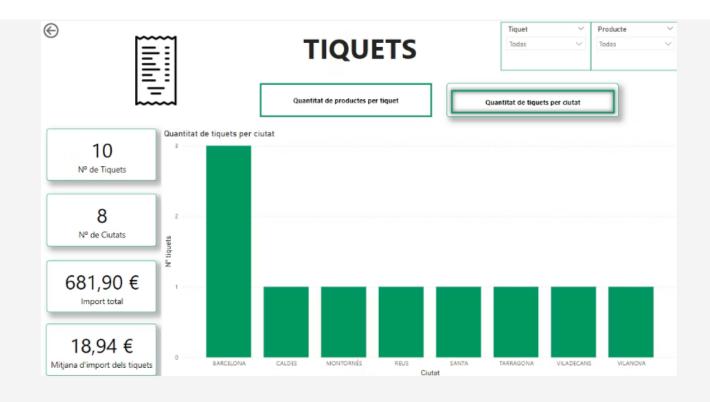
Pantalles que composen el nostre Power Bi

#### Inici

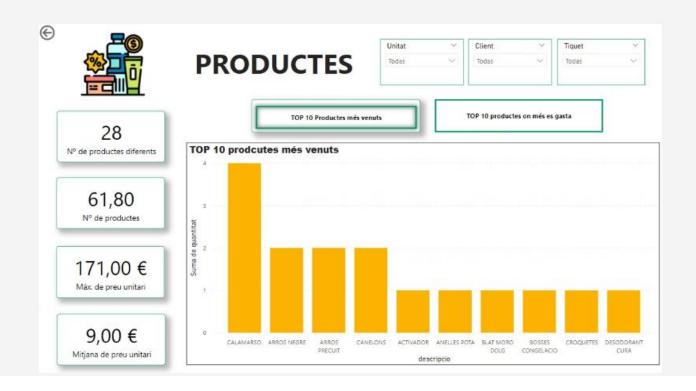


#### Tiquets



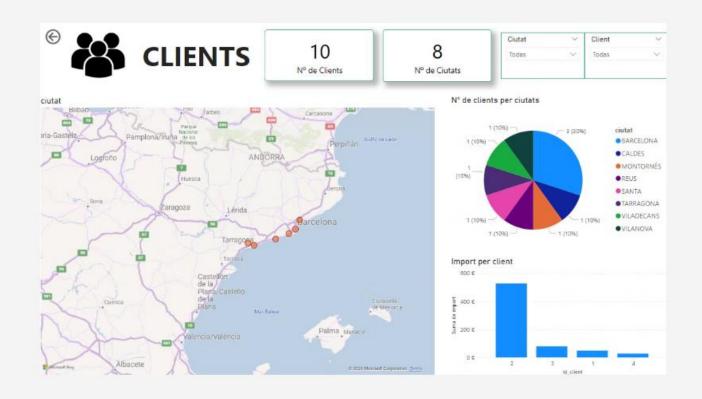


#### **Productes**





#### Clients



## Preguntes?

